



# Métodos Computacionais em Física de Altas Energias

## Exercício #3

---

### Seleção de dados – Instruções gerais

Neste exercício, você irá utilizar dados reais do experimento LHCb para o decaimento  $B^0 \rightarrow K^{*0} \mu^+ \mu^-$  e dados simulados correspondentes. O objetivo é estudar a distribuição de massa do  $B^0$ , aplicar cortes no score de um classificador XGBoost, realizar ajustes de máxima verossimilhança usando `zfit`, otimizar a figura de mérito (FoM), calcular a significância do sinal via teorema de Wilks e, por fim, aplicar técnicas de reweighting com XGBoost para corrigir discrepâncias entre dados e simulação.

### Dataset:

`/shared_dataset/Met_Stat_HEP_AI_School/Kstarmumu_Data_2016_RM_xgb.csv`

`/shared_dataset/Met_Stat_HEP_AI_School/Kstarmumu_MC_xgb.csv`

`/shared_dataset/Met_Stat_HEP_AI_School/Kstarmumu_Data_2016_Jpsi.csv`

**Imports:** `NumPy`, `pandas`, `matplotlib`, `scikit-learn`, `zfit`, `hepstats`, `xgboost`

### Exercise 1: Resultado do treinamento em dados reais

- Carregue o dataset real e visualize a distribuição da variável `xgb_score` em escala linear e logarítmica.
- Aplique um corte inicial e compare as distribuições de massa `B0_M` antes e depois do corte.

### Exercise 2: Inferência estatística

Vamos utilizar o resultado do treinamento para tentar limpar nosso sinal  $B^0 \rightarrow K^{*0} \mu^+ \mu^-$  nos dados reais e obter uma estimativa de sua contribuição em relação ao background. Neste exemplo vamos utilizar a ferramenta `zfit`.

- Selecione a janela de massa `[5150, 5600]` MeV.
- Modele o sinal com uma Gaussiana e o background com uma exponencial.
- Faça o ajuste estendido usando `ExtendedUnbinnedNLL` e obtenha o yield de sinal ( $N_S$ ).
- Plote os dados e as PDFs ajustadas.

### Exercise 3: Figure-of-Merit

Para melhor decidir qual corte melhor otimiza o sinal nos dados, vamos definir uma métrica (tipicamente chamado de Figure-of-Merit – FoM):

$$\text{FoM} = \frac{S}{\sqrt{S + B}}, \quad (1)$$

Para obter  $S$  e  $B$ , vamos fazer uma série de etapas:

a) Cálculo da eficiência de sinal:

- Utilize o dataset de Monte Carlo para obter a eficiência relativa de sinal para vários cortes em `xgb_score`.
- Construa uma tabela com as colunas: corte, eficiência relativa e yield estimado.

b) Estimativa do background em função do corte:

- Ajuste uma exponencial aos sidebands (e.g. [5400, 5600] MeV).
- Use a integral da exponencial para estimar o número de eventos de background na janela do sinal.
- Repita o procedimento para cada valor de corte e construa uma tabela com  $B_{\text{est}}$ .

c) Figure-of-Merit e otimização do corte:

- Calcule a FoM  $S/\sqrt{S + B}$  para cada corte.
- Identifique o valor ótimo de `xgb_score` que maximiza a FoM.
- Plote a curva da FoM e destaque o ponto ótimo.

#### Exercise 4: Significância do sinal

Utilizando o teorema de Wilks, vamos demonstrar como obter a significância de um dado sinal.

- Realize o ajuste completo (Gauss + Exp) e o ajuste nulo (somente Exp).
- Calcule  $\Delta(2 \ln L)$  e a significância estatística  $Z = \sqrt{2\Delta \ln L}$ .
- Compare os resultados para cortes diferentes.

#### Exercise 5: Pre-processamento para correções de Monte Carlo

- Use `hepstats.splot.compute_sweights` para obter pesos de sinal e background a partir do melhor ajuste.
- Adicione os pesos ao DataFrame e verifique que  $\sum w_{\text{sig}} \approx N_S$ .
- Compare distribuições de variáveis cinemáticas (e.g.  $B0\_PT$ ) entre:
  - Dados sem peso;
  - Dados ponderados por  $w_{\text{sig}}$ ;

- MC verdadeiro (label=1).

**Exercise 6:** Canal de controle e Reweighting com XGBoost

- Selecione o canal de controle  $B \rightarrow K^* J/\psi(\mu^+ \mu^-)$  e ajuste sua massa.
- Calcule os sWeights para o sinal de  $J/\psi$ .
- Compare distribuições de variáveis ( $B0\_PT$ ,  $B0\_ENDVERTEX\_CHI2$ ) entre:
  - Dados  $J/\psi$  (sWeighted);
  - MC original do sinal.
- Treine um reweighter baseado em `XGBClassifier` usando essas variáveis.
- Avalie o desempenho com a curva ROC e o valor de AUC.
- Plote as distribuições reponderadas e discuta se o reweighting melhorou o acordo entre dados e simulação.